
AUTOVIT

1. Configurare și Explorare Inițială a Datelor (Setup & EDA)

1.1. Încărcarea Datelor


Am utilizat bibliotecile standard pentru Data Science (pandas, numpy, seaborn, sklearn). Datele au fost încărcate în două structuri separate: `train_data` (pentru antrenare și validare cu `RandomSearchCV`) și `test_data` (setul de validare final, neatins în timpul antrenării).

- **Observație inițială:** Setul conține o mixtură complexă de date numerice (ex: Km, Putere), categorice (ex: Marca, Combustibil) și text nestructurat (ex: liste de dotări).
- **Tipurile initiale:** dtypes: float64(9), int64(1), object(27)

1.2. Analiza Datelor Lipsă

Am implementat funcția `plot_missing_data` pentru a cuantifica exact procentul de valori nule (NaN) din fiecare coloană.

- **Diagnostic:** S-au identificat două tipuri de probleme:
 1. **Lipsă Critică (>90%):** Coloane precum Garanție de la producator, Tuning, Autonomie și Capacitate baterie erau aproape goale.
 2. **Lipsă Moderată:** Atribute esențiale precum Emisii CO2, Consum sau Tara de origine aveau procente semnificative de valori lipsă, necesitând strategii de imputare (completare).



Barplot-ul cu procente de valori lipsă (generat la început)

Figura 1: Analiza integrității datelor. Se observă atributele care necesită eliminare versus cele care necesită imputare.

2. Preprocesare: Faza 1 - Encodare și Feature Engineering

Înainte de a imputa valorile lipsă, am transformat datele brute într-un format numeric preliminar pentru a putea aplica logici de curățare avansate.

2.1. Conversia Atributelor Binare și Extragerea Numerelor

- **Mapare Binară:** Coloanele care conțineau valori de tip text (Da, Nu, True, False) au fost standardizate în format numeric (1 și 0) folosind un dicționar de mapare. Acest pas a fost esențial pentru atribute precum Are VIN sau Tuning.
- **Selectare attribute boolene:** Am cautat toate atributele care au numai două valori distincte din următoarea listă: 'bool_patterns = ['yes', 'no', 'true', 'false', '1', '0', 'y', 'n', 'da', 'nu', 'nan', 'none', 'null']', astfel determinând dacă o coloană este validă pentru transformarea valorilor în Boolean.

- **Selectare atribute pentru One-Hot Encoding:** Am cautat toate atributele care au mai puțin de 15 valori unice și care nu fac parte din setul descris mai sus pentru valori boolene.

Potential object columns to convert to boolean:

- 'Are VIN (Serie sasiu)'
- 'Primul proprietar (de nou)'
- 'Fara accident in istoric'
- 'Tuning'

Potential object columns to apply one-hot encoding:

- 'Ofertă de' with 2 unique values: ['Firma' 'Privat']
- 'Combustibil' with 8 unique values: ['Benzina' 'Diesel' 'Hibrid' 'Plug-In Hybrid' 'Electric' 'Benzina + GPL' 'Benzina + CNG' 'Hibrid Plug-In']
- 'Transmisie' with 4 unique values: ['Fata' '4x4 (automat)' '4x4 (manual)' 'Spate']
- 'Cutie de viteze' with 2 unique values: ['Automata' 'Manuala']
- 'Tip Caroserie' with 9 unique values: ['Compacta' 'Combi' 'SUV' 'Sedan' 'Coupe' 'Masina de oras' 'Monovolum' 'Masina mica' 'Cabrio']
- 'Culoare' with 12 unique values: ['Argint' 'Albastru' 'Negru' 'Gri' 'Alb' 'Bej' 'Rosu' 'Maro' 'Verde' 'Alte culori' 'Portocaliu' 'Galben/Auriu']
- 'Stare' with 2 unique values: ['Second hand' 'Nou']
- 'Norma de poluare' with 13 unique values: ['Euro 4' 'Euro 6' 'Euro 5' 'Euro 6d-Temp' 'Euro 6d' 'Euro 6b' 'Euro 6c' 'Euro 5b' 'Euro 3' 'Euro 5a' 'Non-euro' 'Euro 1' 'Euro 2']

Columns with too many unique values to one-hot encode:

- 'nume' with 8188 unique values
- 'Marca' with 66 unique values
- 'Model' with 622 unique values
- 'Versiune' with 6837 unique values
- 'Garantie dealer (inclusa in pret)' with 55 unique values
- 'Tara de origine' with 29 unique values
- 'Data primei inmatriculari' with 3183 unique values
- 'Garantie de la producator pana la' with 470 unique values
- 'Autonomie' with 146 unique values
- 'Capacitate baterie' with 75 unique values

- **Extragerea Datelor din Text (EVs):** Pentru coloanele “Autonomie”, “Capacitate baterie” și “Garantie dealer (inclusa in pret)” datele erau sub formă de text (ex: "300 km"). Am aplicat o funcție regex pentru a extrage doar valoarea numerică, pregătind terenul pentru analiza vehiculelor electrice.

2.2. One-Hot Encoding

Pentru atributele categorice fără o ordine intrinsecă (precum Marca, Combustibil, Culoare), am aplicat **One-Hot Encoding** (pd.get_dummies). Aceasta a transformat fiecare categorie într-o coloană separată (ex: Combustibil_Diesel = 1/0), permițând algoritmilor matematici să proceseze informația.

2.3. Feature Engineering: Dotări și Garanții

Aceasta a fost o etapă critică de extragere a valorii din datele nestructurate.

- **List[String] -> Numeric:** Coloanele precum “Audio si tehnologie” sau “Siguranta” conțineau liste lungi de echipamente. Am transformat aceste liste într-un singur predictor numeric: **Numărul de Dotări** (numărând elementele separate prin virgulă). Ipoteza validată ulterior este că un număr mai mare de dotări corelează cu un preț mai ridicat.

- **Garanția Dealer:** Valorile lipsă din această coloană au fost considerate ca fiind "lipsa garanției" și înlocuite cu 0.


3. Preprocesare: Faza 2 - Curățare Avansată

Aici am aplicat reguli specifice domeniului auto pentru a corecta datele lipsă într-un mod logic, nu doar statistic.

3.1. Tratarea Vehiculelor Electrice (Smart Imputation)

Am identificat o problemă logică: multe mașini electrice aveau Emisii CO2 necompletate (NaN).

- **Investigație:** Am izolat mașinile care aveau date valide despre Autonomie și Capacitate baterie.
- **Corelație:** Graficul de tip Scatter Plot a confirmat că datele pentru baterie sunt valide (baterie mai mare = autonomie mai mare).



Scatter Plot - Capacitate Baterie vs. Autonomie

Figura 2: Validarea datelor pentru vehiculele electrice.

(Coeficientul de corelație Pearson este: 0.47)

- **Acțiune:** Pe baza acestei validări, am identificat mașinile electrice și am setat forțat Emisii CO2 = 0 pentru acestea.

```

Valori Emisii CO2 existente:
Emisii CO2
NaN    277
Name: count, dtype: int64

Tipuri de combustibil detectate în acest subset:
Combustibil_Benzina + CNG      0
Combustibil_Benzina + GPL      0
Combustibil_Diesel             0
Combustibil_Electric           277
Combustibil_Hibrid              0
Combustibil_Hibrid Plug-In      0
Combustibil_Plug-In Hybrid      0
dtype: int64

```

- **Curățare:** După ce informația a fost extrasă pentru a corecta emisiile, am eliminat coloanele Autonomie și Capacitate baterie din setul final, deoarece acestea erau goale pentru 98% din mașini (cele cu combustie).

3.2. Eliminarea Coloanelor Irelevante (Feature Selection 1)

Am eliminat attributele care au fost identificate ca zgomot sau redundante în faza de EDA: nume (text liber), Versiune, Garantie de la producator pana la (prea multe lipsuri), Data primei inmatriculari (redundant cu Anul fabricației) și Model.

3.3. Imputarea Finală (Numerică)

Pentru toate celelalte coloane numerice (Km, Putere, Consum, etc.) care mai aveau valori lipsă, am aplicat imputarea cu **Mediana**. Aceasta metodă este preferată mediei aritmetice deoarece este robustă la outlieri (valori extreme care ar putea distorsiona media).


```

✓ Valorile numerice lipsă au fost umplute cu mediana.
✓ Țările lipsă au fost marcate ca 'Necunoscuta'.
Cele 15 mărci păstrate: ['Mercedes-Benz', 'BMW', 'Volkswagen', 'Audi', 'Ford', 'Skoda', 'Renault', 'Dacia', 'Volvo', 'Toyota', 'Opel',
'Hyundai', 'Peugeot', 'Nissan', 'Land Rover', 'Mazda', 'Seat', 'Kia', 'Porsche', 'Citroën']
✓ Marca a fost redusă la Top 20 + 'Altele'.

```

4. Analiza Țintei și a Corelațiilor (Statistici Post-Procesare)

După curățarea completă a datelor, am analizat și relația catorva attribute categorice cu pretul pentru a observa distribuția datelor și prezenta outlierilor:




- **Primul graphic:** tendință clară de creștere a prețului median odată cu numărul de porțiere. Această progresie sugerează că vehiculele cu mai multe porțiere sunt asociate cu modele mai mari și mai scumpe.
- **Al doilea graphic:** pentru vehiculele cu 2 până la 6 locuri, mediana prețului rămâne relativ constantă, cu variații moderate. Însă categoria cu 6 de locuri, care include vehicule mari, prezintă o variabilitate extremă, cu prețuri care ajung până la peste 100.000. Acest lucru indică prezența unor vehicule de mare capacitate în dataset, care distorsionează semnificativ distribuția.
- **Al treilea graphic:** Aici se observă cea mai detaliată categorizație, cu multiple niveluri de echipare care arată o corelație clară între sofisticarea tehnologică și preț. Aproape toate categoriile conțin outlieri, ceea ce sugerează că există vehicule premium în fiecare segment de echipare.
- **Ultimul graphic:** Vehiculele electrice și cele din categoriile superioare au prețuri mediane mai mari decât vehiculele convenționale, reflectând costul tehnologiei de propulsie alternativă. Categoria hibridă prezintă cea mai mare variabilitate, probabil datorită diversității de modele hibride disponibile pe piață, de la compacte economice până la SUV-uri de lux.

Se evidențiază prezența constantă a outlierilor în toate categoriile, indicând existența unor vehicule premium sau de lux în dataset. Variabilitatea prețurilor crește în general odată cu complexitatea și tehnologia vehiculului, iar range-ul complet de prețuri se întinde de la aproape zero până la aproximativ 100.000 de euro.


4.1. Distribuția Prețului și Transformarea Logaritmică

Analiza histogramei prețului a arătat o distribuție asimetrică la dreapta (multe mașini ieftine, puține scumpe).



Skewness (Asimetrie) - Date Originale: 5.01


- **Decizie:** Am aplicat transformarea np.log1p asupra prețului.
- **Rezultat:** Distribuția a devenit aproximativ normală (Gaussiană), ceea ce este ideal pentru modelele de regresie, stabilizând varianța erorilor.



Skewness (Asimetrie) - Date Transformate: 0.13

Figura 3: Distribuția prețului după transformarea logaritmice.

4.2. Analiza Corelațiilor (Heatmap & Scatter)



Am calculat corelația Pearson a tuturor atributelor cu LOG_PRET.

- **Descoperiri:** Cei mai puternici predictori pozitivi au fost Anul fabricației și Putere. Predictorii negativi puternici au fost Km.
- **Validare Outlieri:** Graficele Boxplot și Scatter Plot (Putere vs. Preț) au confirmat că valorile extreme (prețuri mari) sunt valide (asociate cu putere mare și ani recenti), nu erori.




Figura 4: Identificarea outlierilor (mașini de lux vs. mașini ieftine).




Figura 5: Verificarea consistenței logice a datelor (Putere mai mare implică Preț mai mare).

5. Standardizare și Selecție Finală

5.1. Scalarea Datelor (StandardScaler)

Am aplicat StandardScaler pe toate attributele numerice. Acest pas a adus toate variabilele la aceeași scară (medie 0, deviație standard 1), prevenind ca attributele cu valori mari (ex: Km de ordinul sutelor de mii) să domine attributele cu valori mici (ex: Anul fabricației) în modelele sensibile la distanțe (precum SVR).

5.2. Eliminarea Multicoliniarității (Feature Selection 2)

Pe baza analizei de corelație, am eliminat attributele redundante pentru a simplifica modelul:

- Capacitate cilindrica: Eliminată deoarece avea o corelație de 0.77 cu Putere (informație duplicată).
 - Consum Extraurban: Eliminată (corelație >0.9 cu Consum Urban).
 - Numar de portiere / Numar locuri: Eliminate din cauza corelației nesemnificative cu prețul.
-

6. Modelare și Evaluare

6.1. Baseline: Linear Regression (Ridge)

- **Rezultate:** $R^2 = 0.8178$ | $MAE = 4,721$ | $MSE = 1.56 \cdot 10^8$
- **Configurație Optimă:** $\alpha = 98.8$, $\text{solver} = \text{'svd'}$
- **Analiza:**
 - Modelul liniar a stabilit un nivel de bază surprinzător de ridicat ($R^2 > 0.80$), ceea ce sugerează că o parte semnificativă din variația prețului poate fi explicată prin relații liniare (ex: scăderea prețului odată cu vârsta).
 - Totuși, eroarea medie de peste 4.700 € este cea mai mare dintre toate modelele, confirmând că o simplă linie dreaptă nu poate captura nuanțele pieței auto.

6.2. Random Forest Regressor

- **Rezultate:** $R^2 = 0.8454$ | $MAE = 4,446$ | $MSE = 1.33 \cdot 10^8$
- **Configurație Optimă:** $n_estimators = 287$, $max_depth = 15$, $min_samples_leaf = 19$
- **Analiza:**
 - Deși este un model robust, Random Forest s-a clasat sub SVR.
 - Cauza probabilă: Parametrul $min_samples_leaf = 19$ (impus de căutarea aleatorie) a forțat arborele să aibă frunze cu minim 19 mașini. Aceasta este o constrângere puternică de regularizare, care a împiedicat modelul să învețe particularitățile mașinilor mai rare sau unice, ducând la o ușoară sub-fitare ("underfitting") comparativ cu potențialul maxim al algoritmului.

6.3. SVR (Support Vector Regressor)

- **Rezultate:** $R^2 = 0.8687$ | **MAE** = 3,859 | **MSE** = $1.13 \cdot 10^8$
- **Configurație Optimă:** `kernel='rbf'`, `C = 31.4`, `gamma='auto'`
- **Analiza:**
 - SVR a depășit Random Forest, obținând un scor R^2 de aproape 0.87.
 - Nucleul radial (rbf) a permis modelarea eficientă a spațiului neliniar al prețurilor. Valoarea `C=31.4` indică faptul că modelul a fost lăsat să penalizeze erorile de antrenare suficient de mult pentru a se mula bine pe date, fără a pierde generalizarea (datorită pre-scalării corecte a datelor).

6.4. Gradient Boosting Regressor (Câștigătorul)

- **Rezultate:** $R^2 = 0.9101$ | **MAE** = 3,495 | **MSE** = $7.72 \cdot 10^7$
- **Configurație Optimă:** `learning_rate=0.1`, `n_estimators=234`, `max_depth=7`, `subsample=0.8`
- **Analiza Performanței:**
 - Acesta este, indiscutabil, cel mai performant model, fiind singurul care a depășit pragul de 0.90.
 - Factori de succes: Adâncimea arborilor (`max_depth=7`) este mai mare decât cea tipică pentru boosting (3-5), ceea ce a permis fiecărui estimator să captureze interacțiuni complexe. Rata de învățare de 0.1 combinată cu 234 estimatori a oferit echilibrul perfect între viteza de convergență și precizie.
 - Impact: Eroarea medie a scăzut la aprox. 3.500.

Performanțele Finală pe Setul de Testare

Loc	Algoritm	Parametri Optimi (Rezumat)	R^2 Score	MAE (Euro)	MSE
1	Gradient Boosting	<code>lr=0.1</code> , <code>depth=7</code> , <code>est=234</code> , <code>sub=0.8</code>	0.9101	3,495 €	$7.72e+07$
2	GBR Quantile (Median)	<code>alpha=0.5</code> , <code>est=200</code> , <code>depth=5</code> , <code>lr=0.1</code>	0.8710	3,849 €	-
3	SVR (Tuned)	<code>C=31.4</code> , <code>kernel='rbf'</code> , <code>gamma='auto'</code>	0.8687	3,859 €	$1.13e+08$

Loc	Algoritm	Parametri Optimi (Rezumat)	R ² Score	MAE (Euro)	MSE
4	Random Forest	est=287, depth=15, leaf=19	0.8454	4,446 €	1.33e+08
5	Linear Ridge	alpha=98.8, solver='svd'	0.8178	4,721 €	1.56e+08

6.5. Regresia cu Cuantile (Analiza Incertitudinii)

Pentru a gestiona riscul inerent predicției punctuale, am utilizat modelul Gradient Boosting cu funcția de pierdere loss='quantile'.

- **Configurație:** Am antrenat 3 modele distincte pentru percentilele alpha=0.05 (optimist), alpha=0.50 (mediană) și alpha =0.95 (pesimist).
- **Rezultat:**
 - Modelul median (alpha=0.) a obținut un scor R² de 0.8710, comparabil cu SVR și foarte aproape de modelul standard.
 - Intervalul de Predicție: Am generat un interval de încredere de 90%. Graficul rezultat a demonstrat o heteroscedasticitate corectă: banda de predicție este îngustă pentru mașinile ieftine (incertitudine redusă) și se lărgeste considerabil pentru mașinile scumpe, reflectând volatilitatea reală a pieței de lux.




Figura 6: Predicția mediană și intervalul de încredere de 90

